Sensordatenhandling

Parameter	Kursinformationen
Veranstaltung:	`Softwareprojekt Robotik`
Semester	`Wintersemester 2022/23`
Hochschule:	`Technische Universität Freiberg`
Inhalte:	`Umsetzung von ROS Paketen`
Link auf GitHub:	https://github.com/TUBAF-IfI-LiaScript/VL_SoftwareprojektRobotik/blob/master/10_Sensordatenhandling.md
Autoren	Sebastian Zug & Georg Jäger

|

Wie weit waren wir gekommen?

... wir generieren ein "rohes" Distanzmessignal und wollen dies weiterverwenden. Dafür konfigurieren wir eine Verarbeitungskette aus den nachfolgenden Elementen.

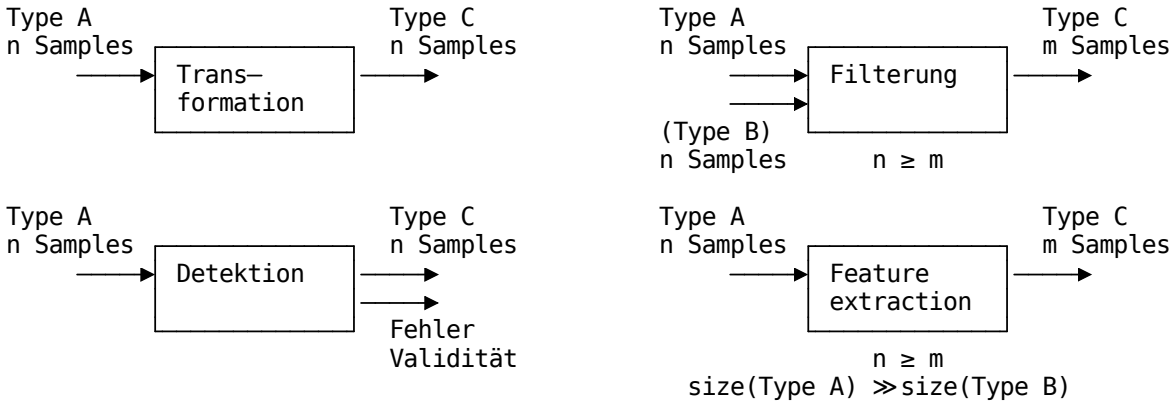

Beispiele für Datenvorverarbeitung

- Aufbereitung der Daten, Standardisierung
- zeitliche Anpassung
- Fehler, Ausreißer und Rauschen erkennen und behandeln,
- Integration oder Differenzierung
- Feature-Extraktion (Gesichter auf Positionen, Punktewolken auf Linien, Flächen, Objekte)

Transformation

Ableitung der eigentlichen Messgröße

Ein Aspekt der Transformation ist die Abbildung der Messdaten, die ggf. als Rohdaten des Analog-Digital-Wandlers vorliegen auf die eigentlich intendierte Messgröße.

Beispiel: Gyroskop MPU9250 mit internem 16bit ADC und variablem Meßbereich.

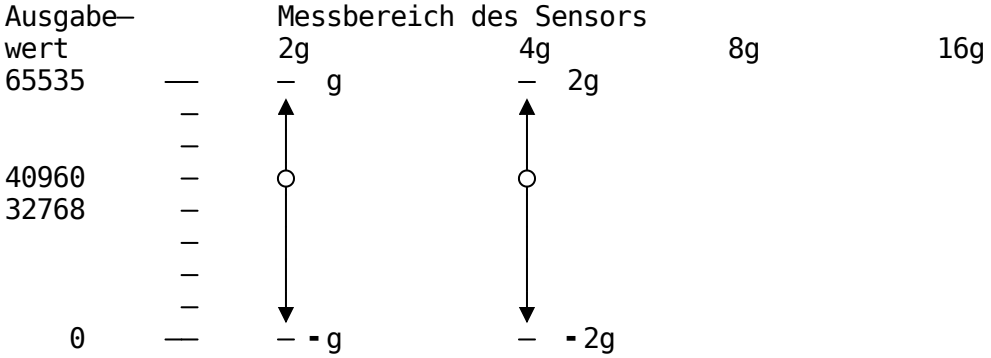

$$a = \frac{Messbereich}{Auflösung} \cdot ADCvalue - \frac{1}{2} Messbereich$$

Die Gleichung beschreibt einen linearen Zusammenhang zwischen der Messgröße und dem ADC Wert. Allerdings müssen ggf. auch nichtlineare Zusammenhänge abgebildet werden.

Beispiel: Analoger Distanzsensor GP2D12 (vgl. Übersicht unter Link)

Sensorkennlinie eines GP2Y0A21 Sensors Link

Offenbar benötigen wir hier ein nichtlinerares Approximationsmodell. Die Entsprechenden Funktionen können sehr unterschiedlich gewählt werden ein Beispiel ist die Erzeugung eines Polynoms, dass das intendierte Verhalten abbildet.

Allgemeines Vorgehen bei der Approximation eines Polynoms

Polynom

$$y(x) = a_0 + a_1 x + a_a x^2 + ... + a_n x^n$$

1. Definition des Grades des Polynoms (lineare, quadratische, kubische … Relation)
2. Generierung der Messpunkte (m-Stützstellen) – x_m, y_m
3. Aufstellen des Gleichungssystems

$$y_0(x_0) = a_0 + a_1 x_0 + a_a x_0^2 + ... + a_n x_0^n$$

$$y_1(x_2) = a_0 + a_1 x_1 + a_a x_1^2 + ... + a_n x_1^n$$

$$y_2(x_2) = a_0 + a_1 x_2 + a_a x_2^2 + ... + a_n x_2^n$$

$$y = Am$$

4. Lösen des Gleichungssystems (Methode der kleinsten Quadrate)
5. Evaluation des Ergebnispolynoms
6. evtl. Neustart

Abhängigkeit der Abbildung vom Grad des Polynoms

Umsetzung im RoboterSystem

$$y(x) = a_0 + a_1 x + a_a x^2 + ... + a_n x^n$$

mit $2 \cdot (n-1)$ Multiplikationen und n Additionen. Einen rechnerisch günstigere Implementierung bietet das Horner Schema, das die Exponentialfunktionen zerlegt:

$$y(x) = a_0 + x \cdot (a_1 + x \cdot (... + a_n x^n))$$

damit verbleiben n Multiplikationen und n Additionen.

Für aufwändige mehrdimensionale Kennlinien bietet sich im Unterschied zur funktionalen Abbildung eine Look-Up-Table an, die die Daten in Form eines Arrays oder Vektors speichert.

LookUpTable

```
static const uint8_t lookup[256] =
{0,0,0,0 … 20,23,26,30,31,30,28,-..,4,4,4,4,4,3,3,3,…0,0,0};
distance= lookup[ADC_output]
```

Welche Vor- und Nachteile sehen Sie für die gegensätzlichen Ansätze?

Koordinatentransformation

Die Transformation eines Datensatzes aus einem Koordinatensystem in ein anderes betrifft sowohl die Übertragung zwischen unterschiedlichen Darstellungsformen als auch den Wechsel des Bezugsystems.

Gehen wir von einem Laserscan aus. Dieser wurde in Polarkoordinaten erfasst, um aber die Frage zu klären, wie weit dieser von der Frontseite unserer Roboters entfernt ist, müssen wir zunächst die Sample in ein kartesisches Koordinaten übersetzen, dessen Ursprung wir auf die fordere Kante des Roboters legen.

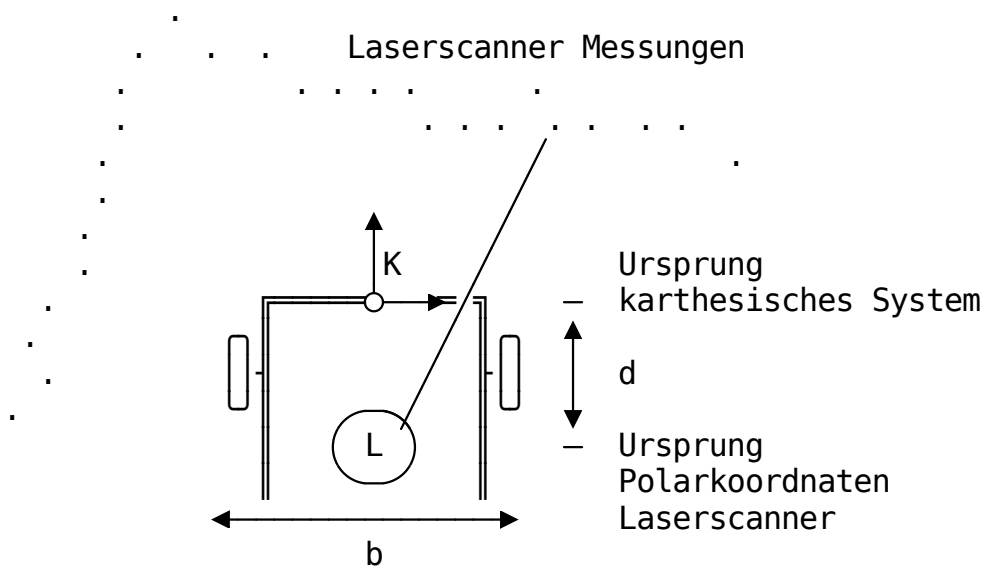

Der Laserscanner generiert eine Folge von Paaren $[\rho, r]_k$, die die Winkellage und die zugehörige Entfernung zum Punkt bezeichnet.

Schritt 1: Transformation der der Polarkoordinaten

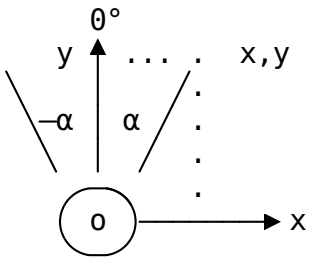

$$\begin{bmatrix} x_L \\ y_L \end{bmatrix} = r \cdot \begin{bmatrix} sin(\rho) \\ cos(\rho) \end{bmatrix}$$

Schritt 2: Transformation in neues Koordinatensystem

$$\begin{bmatrix} x_K \\ y_K \end{bmatrix} = \begin{bmatrix} x_L \\ y_L \end{bmatrix} + \begin{bmatrix} 0 \\ d \end{bmatrix}$$

Schritt 3: Filtern der relevanten Datensamples

Wir filtern zunächst erst mal nach den Samples, die unmittelbar vor dem Roboter liegen, für die also gilt $-\frac{b}{2} <= x <= \frac{b}{2}$. Für diese wird dann geprüft, ob ein y-Wert kleiner als eine Schwelle vorliegt.

> **Aufgabe:** Wie müssten wir die Berechnung anpassen, wenn der Laserscanner aus baulichen Gründen um 90 Grad verdreht wäre.

Filterung

> das/der Filter feltrare, "durchseihen"; ursprünglich "durch Filz laufen lassen" zu germanisch felt = "Filz"

Ziel:

- Reduzierung des Rauschens
- Löschung von fehlerhaften Werten
- Konzentration der Daten

Ein Filter bildet die Folge x_i der Sensorwerte auf eine Folge y_i ab. Die Domäne, in der der Filter arbeitet, kann im Zeit oder Frequenzbereich liegen. Als Vorwissen auf seiten des Entwicklers kann die Signalspezifikation oder ein Systemmodell angenommen werden.

Gleitender Mittelwert

Ein Ansatz für die Glättung sind gleitende Fenster, innerhalb derer die Daten analysiert werden.

> Anders als in (offline) Zeitreihen-Analysen leiten wir den Ausgabewert ausschließlich von den zuvor erfassten Werten ab.

$$y_k(x_k, x_{k-1}, x_{k-2} ... x_{k-N+1})$$

mit N als Fenstergröße

Zeitreihen würden auch die nachfolgenden Werte berücksichtigen!

$$y_k(\ldots x_{k+2}, x_{k+1}, x_k, x_{k-1}, x_{k-2}\ldots)$$

Damit laufen wir den Messdaten zeitlich gesehen hinterher!

Ein gleitender Mittelwert wird häufig als Allheilmittel für die Filterung von Messwerten dargestellt, manipuliert das Signal aber auch entsprechend:

$$y_k = \frac{1}{N}\sum_{i=0}^{i<N} x_{k-i}$$

Im folgenden Beispiel wird ein niederfrequentes Bewegungsmuster mit einem höherfrequenten Störsignal überlagert. Welche Veränderungen erkennen Sie am Ausgabesignal des Filters verglichen mit dem Originalsignal?

Data.js

```
const window_size = 3;

var xrange = d3.range(0, 4*Math.PI, 4 * Math.PI/100);
var ideal_values = xrange.map(x => Math.sin(x));
var noise = d3.range(0, 100, 1).map(d3.randomNormal(0, 0.1));
var noisy_values = new Array(xrange.length).fill(0);
for (var i = 0; i <= noise.length; i++){
    noisy_values[i] = ideal_values[i] + noise[i];
}
```

SlidingWindow.js

```
//Actual filter method (moving average)
function slidingWindow(randoms, window_size) {
    var result = new Array(randoms.length).fill(null);
    for (var i = window_size; i < randoms.length; i++) {
        var window = randoms.slice(i - window_size, i);
        result[i] = window.reduce(function(p,c,i,a){return p + (c/a.le
          ,0);
    }
    return result;
}
```

Visualize.js

```
var mean = slidingWindow(noisy_values, window_size);

var layout = {
    height : 300,
    width :  650,
    xaxis: {range: [0, 10]},
    margin: { l: 60, r: 10, b: 0, t: 10, pad: 4},
    showlegend: true,
    legend: { x: 1, xanchor: 'right', y: 1},
    tracetoggle: false
};

var trace1 = {
  x: xrange,
  y: ideal_values,
  name: 'Ideales Signal',
  mode: 'line'
};

var trace2 = {
  x: xrange,
  y: noisy_values,
  name: 'Verrauschtes Signal',
  mode: 'line'
};

var trace3 = {
  x: xrange,
  y: mean,
  name: 'Mittelwertfilter',
  mode: 'line'
};
Plotly.newPlot('chart1', [trace1, trace2, trace3], layout);
```

```
No DOM element with id 'chart1' exists on the page.
```

Welche Abwandlungen sind möglich, um die Eigenschaften des Filters zu verbessern?

1. Gewichteter Mittelwert

Wir gewichten den Einfluß der einzelnen Elemente individuell. Damit können jüngere Anteile einen höheren Einfluß auf die Ausgabe nehmen als ältere.

$$y_k = \sum_{i=0}^{i<N} w_i \cdot x_{k-i}$$

mit

$$\sum_{i=0}^{i<N} w_i = 1$$

2. Exponentielle Glättung

Die Glättung der Mittelwerte selbst steigert die Filtereigenschaften und erhöht die Dynamik des Filters.

$$\overline{y_k} = \alpha \cdot y_{k-1} + (1-\alpha) \cdot y_k$$

Der Wert von α bestimmt in welchem Maße die "Historie" der Mittelwerte einbezogen wird.

Medianfilter

Einen alternativen Ansatz implementiert der Medianfilter. Hier wird untersucht, welcher Wert den größten Abstand zu allen anderen hat und damit für einen vermuteten Ausreißer steht.

$$\sum_{i=1}^{N} \|\vec{x}_{\mathrm{VM}} - \vec{x}_i\|_p \leq \sum_{i=1}^{N} \|\vec{x}_j - \vec{x}_i\|_p$$

$$\vec{x}_{\mathrm{VM}} = \arg\min_{\vec{x}_j \in X} \sum_{i=1}^{N} \|\vec{x}_j - \vec{x}_i\|_p$$

Der Median-Filter ist ein nichtlinearer Filter, er entfernt Ausreißer und wirkt damit als Filter und Detektor!

Die nachfolgende Abbildung zeigt ein Beispiel für die Anwendung des Medianfilters im 2d Raum. Laserscannerdaten werden hier geglättet. Die Punkte werden in Abhängigkeit von den Abständen zwischeneinander.

Anwendung des Medianfilters auf Laserscans

Detektion

Die Detektion zielt auf die Erfassung von Anomalien im Signalverlauf. Dabei werden Modelle des Signalverlaufes oder der Störung genutzt, um

- Ausreißer (single sample)
- Level shifts (mehrere aufeinander folgende Samples)
- veränderliches Noiseverhalten
- ...

zu erfassen. Auch hier lassen sich sehr unterschiedliche Ansätze implementieren, das Spektrum der Lösungen soll anhand von zwei Lösungsansätze diskutiert werden.

Begonnen werden soll mit einem einfachen Schwellwerttest, der die Änderung zwischen zwei Messungen berücksichtigt. Welches Parameter des Signals sind für den Erfolg dieser Methode maßgeblich bestimmend?

GenerateData.js

```
var sampleCount = 100;
function generateStep(xrange, basis, step, step_index){
  var result = new Array(xrange.length).fill(basis);
  return result.fill(step, step_index);
}
var xrange = d3.range(0, sampleCount, 1);
var ideal_values = generateStep(xrange, 3.5, 1, 50);
var noise = d3.range(0, sampleCount, 1).map(d3.randomNormal(0, 0.1));
var noisy_values = new Array(xrange.length).fill(0);
for (var i = 0; i <= noise.length; i++){
    noisy_values[i] = ideal_values[i] + noise[i];
}
```

Processing.js

```
var diff = new Array(xrange.length).fill(0);
for (var i = 1; i <= noise.length; i++){
    diff[i] = noisy_values[i-1] - noisy_values[i];
}
```

Visualization.js

```javascript
var layout = {
    height : 300,
    width :  650,
    xaxis: {range: [0, sampleCount]},
    margin: { l: 60, r: 10, b: 0, t: 10, pad: 4},
    showlegend: true,
    legend: { x: 1, xanchor: 'right', y: 1},
    tracetoggle: false
};

var trace1 = {
  x: xrange,
  y: ideal_values,
  name: 'Ideal step function',
  mode: 'line'
};

var trace2 = {
  x: xrange,
  y: noisy_values,
  name: 'Noisy measurements',
  mode: 'markers'
};
Plotly.newPlot('rawData', [trace1, trace2], layout);

var trace1 = {
  x: xrange,
  y: diff,
  name: 'Derivation of the signal',
  mode: 'line'
};
Plotly.newPlot('derivedData', [trace1], layout);

```

```
No DOM element with id 'rawData' exists on the page.
```

Allein aus dem Rauschen ergibt sich bei dieser Konfiguration $\sigma = 0.1$ eine stochastisch mögliche Änderung von $6 \cdot \sigma = 0.6$. Für alle Werte oberhalb dieser Schranke kann mit an Sicherheit grenzender Wahrscheinlichkeit angenommen werden, dass eine Verschiebung des eigentlichen Messgröße vorliegt.
Welche Verfeinerung sehen Sie für diesen Ansatz?
Unter der Berücksichtigung des gefilterten Signalverlaufes, der zum Beispiel mit einem Mittelwert-Filter erzeugt wurde, können wir aber auch die Erklärbarkeit der Messungen untersuchen.

GenerateData.js

```javascript
var sampleCount = 100;

function generateStep(xrange, basis, step, step_index){
  var result = new Array(xrange.length).fill(basis);
  return result.fill(step, step_index);
}

var xrange = d3.range(0, sampleCount, 1);
var ideal_values = generateStep(xrange, 0.5, 1, 50);
var noise = d3.range(0, sampleCount, 1).map(d3.randomNormal(0, 0.1));
var noisy_values = new Array(xrange.length).fill(0);
for (var i = 0; i <= noise.length; i++){
  noisy_values[i] = ideal_values[i] + noise[i];
}
```

Processing.js

```javascript
function slidingAverage(randoms, window_size) {
    var result = new Array(randoms.length).fill(null);
    for (var i = window_size; i < randoms.length; i++) {
        var window = randoms.slice(i - window_size, i);
        result[i] = window.reduce(function(p,c,i,a){return p + (c/a.l
          )},0);
    }
    return result;
}

const window_size = 5;
var mean = slidingAverage(noisy_values, window_size);

var diff = new Array(xrange.length).fill(0);
for (var i = 1; i <= noise.length; i++){
  diff[i] = mean[i] - noisy_values[i];
}
```

Visualization

```
var layout = {
    height : 300,
    width :  650,
    xaxis: {range: [0, sampleCount]},
    margin: { l: 60, r: 10, b: 0, t: 10, pad: 4},
    showlegend: true,
    legend: { x: 1, xanchor: 'right', y: 1},
    tracetoggle: false
};

var trace1 = {
  x: xrange,
  y: ideal_values,
  name: 'Ideal step function',
  mode: 'line'
};

var trace2 = {
  x: xrange,
  y: noisy_values,
  name: 'Noisy measurements',
  mode: 'markers'
};

var trace3 = {
  x: xrange,
  y: mean,
  name: 'Filtered measurements',
  mode: 'line'
};

Plotly.newPlot('rawDataII', [trace1, trace2, trace3], layout);

var trace1 = {
  x: xrange,
  y: diff,
  name: 'Difference between filtered and original signal',
  mode: 'line'
};
Plotly.newPlot('derivedDataII', [trace1], layout);
```

```
No DOM element with id 'rawDataII' exists on the page.
```

Im Ergebnis zeigt sich eine größere Robustheit des Detektors, da nunmehr nicht mehr die gesamte Streubreite des Rauschens berücksichtigt zu werden ist.

Alternative Filterkonzepte erweitern den Fensteransatz und bewerten die Verteilung der darin enthaltenen Samples. Dabei wird die Verteilung eines Referenzdatensatz mit der jeweiligen Fehlersituation verglichen und die Wahrscheinlichkeit bestimmt, dass die beiden Verteilungen zur gleichen Grundgesamtheit gehören.

Im folgenden soll dies Anhand der Detektion von

Störabhängigkeit eines infrarot-lichtbasierten Distanzsensors in Bezug auf externe Beleuchtung

Konfiguration der Größe des Referenzsamples und des Sliding Windows und deren Auswirkung auf die korrekte Klassifikation (Kolmogoroff-Smirnow) (links Referenzdatensatz, rechts gestörte Messung jeweils mit unterschiedlicher Zahl von Samples)

Zeitliches Verhalten verschiedener Tests - Fligner (links), Mann-Whitney U (rechts))

Abstraktion

Während der Abstraktion werden die Rohdaten im Hinblick auf relevante Aspekte segmentiert und vorverarbeitet. Beispiele dafür sind die

- Extraktion von höherabstrakten Linien, Ebenen, usw. aus Laserscans oder Punktwolken oder Gesichtern in Bildern
- Kategorisierung von Situationen (Form des Untergrundes anhand von Beschleunigungsdaten, Einparkhilfen beim Fahrzeug (grün, gelb, rot))
- Identifikation von Anomalien
- ...

Das ganze fügt sich dann ein in die allgemeine Verarbeitungskette von Daten, die die Abbildung von Rohdaten auf Informationen, Features und letztendlich auf Entscheidungen realisiert. Dabei beruht dieser Fluß nicht auf den Daten eines einzigen Sensors sondern kombiniert verschiedene (multimodale) Inputs.

$$\text{Rohdaten} \xrightarrow[\text{von Relationen}]{\text{Verständnis}} \text{Informationen} \xrightarrow[\text{von Mustern}]{\text{Verständnis}} \text{Wissen} \xrightarrow[\text{von Prinzipien}]{\text{Verständnis}} \text{Weisheit}$$

Eine knappe Einführung in die Grundlagen der Datenfusion folgt in der kommenden Veranstaltung, eine Vertiefung im Sommersemester.

Anwendung einer Rohdatenverarbeitung in ROS

- Kapselung des Sensorinterfaces
- Standardisierung der Nachrichten
- Integration von Metainformationen (Frame ID, Zeitstempel)
- Plausibilitätsinformationen

Transformationen mit tf

Anwendung laser-filters

> Die Aussagen hier beziehen sich auf die ROS1 Implementierung!

Der primäre Inhalt des `laser_filters`-Pakets (Link) besteht aus einer Reihe von Filtern und Transformationsalgorithem für Laserscanner-Rohdaten. Der Anwender konfiguriert dabei die Parameter der Filter in einem Beschreibungsfile, die eigentliche Ausführung übernehmen zwei Knoten, die dann mehrere Filter nacheinander ausführen. Der `scan_to_scan_filter_chain` Knoten wendet eine Reihe von Filtern auf einen `sensor_msgs/LaserScan` an. Die `scan_to_cloud_filter_chain` implementiert zunächst eine Reihe von Filtern auf einen `sensor_msgs/LaserScan` an, wandelt ihn in einen `sensor_msgs/PointCloud` um und wendet dann eine Reihe von Filtern auf den `sensor_msgs/PointCloud` an.

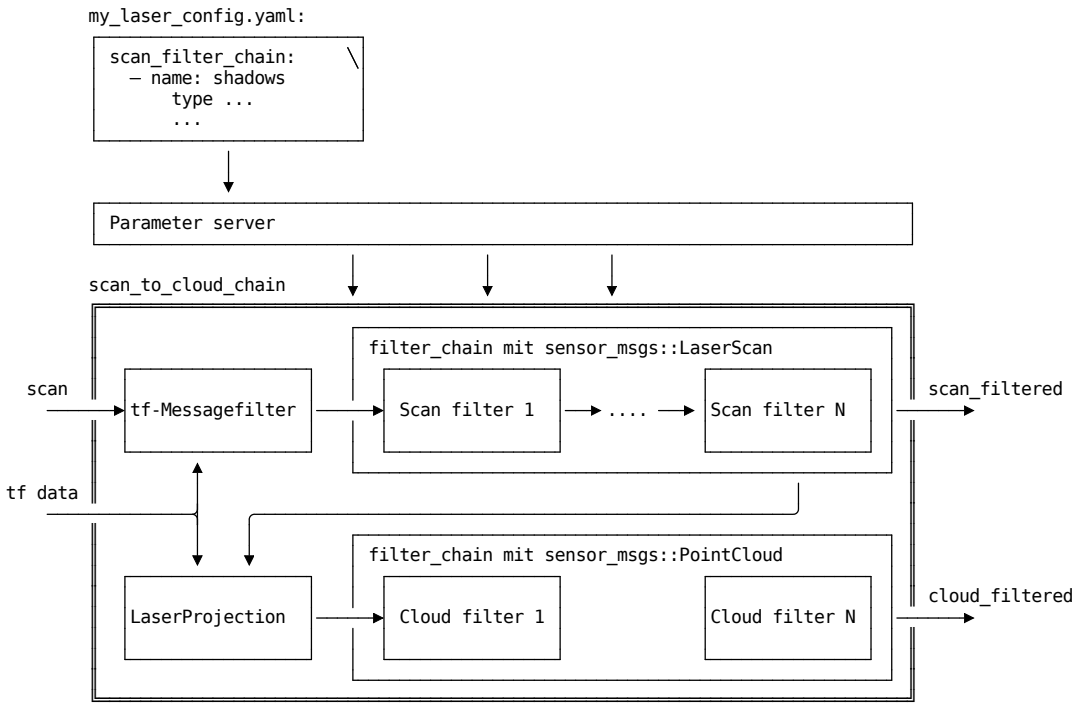

Examplary_laser_filter_config.yaml

```yaml
scan_filter_chain:
- name: shadows
  type: laser_filters/ScanShadowsFilter
  params:
    min_angle: 10
    max_angle: 170
    neighbors: 20
    window: 1
- name: dark_shadows
  type: laser_filters/LaserScanIntensityFilter
  params:
    lower_threshold: 100
    upper_threshold: 10000
    disp_histogram: 0
```

Dabei sind folgende Filtertypen in das Konzept eingebettet:

Bezeichnung	Bedeutung
`ScanShadowsFilter`	eleminiert Geisterreflexionen beim Scannen von Objektkanten.
`InterpolationFilter`	interpoliert Punkte für ungültige Messungen
`LaserScanIntensityFilter`	filtered anhand der Intensität des reflektierten Laserimpulses
`LaserScanRangeFilter`	beschränkt die Reichweite
`LaserScanAngularBoundsFilter`	entfernt Punkte, die außerhalb bestimmter Winkelgrenzen liegen, indem der minimale und maximale Winkel geändert wird.
`LaserScanAngularBoundsFilterInPlace`	überschreibt Werte außerhalb der angegebenen Winkellage mit einem Distanzwert außerhalb der maximalen Reichweite
`LaserScanBoxFilter`	selektiert Messungen, die in einem bestimmten kartesischen Raum liegen.

Aufgabe der Woche

- Implementieren Sie eine exponentielle Glättung für den Durchschnitt im Beispiel zu gleitenden Mittelwert.
- Nutzen Sie Bag-Files, die Sie zum Beispiel unter folgendem Link finden, um eine Toolchain für die Filterung von Messdaten zu implementieren. Experimentieren Sie mit den verschiedenen Filtern.